

Wykład 15

Regresja liniowa

Założmy, że dana jest macierz $X \in \mathbb{R}^{m \times 2}$ o postaci $X = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_m \end{bmatrix}$ oraz wektor

$$Y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}. \text{ Regresja liniowa polega na znalezieniu takiego wektora } \beta = [\beta_1, \beta_2]^T$$

który minimalizuje sumę odległości punktów (x_i, y_i) od prostej $y = \beta_1 + \beta_2 x$. Innymi słowy: chcemy zminimalizować funkcję:

$$f(\beta_1, \beta_2) = \sum_{k=1}^m (\beta_1 + \beta_2 x_k - y_k)^2. \quad (1)$$

Obliczając pochodne cząstkowe funkcji f i przyrównując je do zera otrzymujemy układ równań określający zmienne β_1, β_2

$$\frac{\partial f}{\partial \beta_1} = 2 \cdot \sum_{k=1}^m (\beta_1 + \beta_2 x_k - y_k) = 0, \quad \frac{\partial f}{\partial \beta_2} = 2 \cdot \sum_{k=1}^m ((\beta_1 + \beta_2 x_k - y_k) \cdot x_k) = 0. \quad (2)$$

Pierwsze równanie daje wzór $\beta_1 = \sum_{k=1}^m y_k - \beta_2 \cdot \sum_{k=1}^m x_k$, który zwykle zapisujemy w zwężonej postaci jako $\beta_1 = \bar{y} - \beta_2 \bar{x}$. Wstawienie tego wzoru do drugiego równania daje $0 = \beta_1 \bar{x} + \beta_2 \sum_{k=1}^m x_k^2 - \sum_{k=1}^m x_k y_k = \beta_1 \bar{x} \bar{y} - \sum_{k=1}^m x_k y_k + \beta_2 \left(\sum_{k=1}^m x_k^2 - m \cdot \bar{x}^2 \right)$. Stąd otrzymujemy rozwiązanie równań (2)

$$\beta_2 = \frac{\sum_{k=1}^m (x_k - \bar{x}) \cdot (y_k - \bar{y})}{\sum_{k=1}^m (x_k - \bar{x})^2}, \quad \beta_1 = \bar{y} - \beta_2 \bar{x}.$$

Zwróćmy uwagę, że wzór na β_2 ma prostą interpretację, mianowicie $\beta_2 = \frac{\text{Cov}(X, Y)}{\text{V}(X)}$.

Odległość punktu od prostej jest tutaj definiowana jako $|\beta_1 + \beta_2 x_k - y_k|^2$, nie jest to typowa odległość punktu od prostej, uzasadnienie (powody) nastąpi nieco później. Wzór (1) ma dodatkową interpretację: dla danych X, Y szukamy β taką, że $X \cdot \beta \approx Y$, przy czym β minimalizuje wartość wyrażenia $\|X \cdot \beta - Y\|_2^2$.

Niech zatem $g(\beta_1, \beta_2) = \|X \cdot \beta - Y\|_2^2 = \beta^T X^T X \beta - 2 \cdot Y^T X \beta + Y^T Y$. Bezpośrednim rachunkiem sprawdzamy, że

$$\begin{aligned} \beta X^T X \beta &= [\beta_1, \beta_2] \begin{bmatrix} m & m\bar{x} \\ m\bar{x} & \sum x_k^2 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} = m\beta_1^2 + 2m\bar{x}\beta_1\beta_2 + (\sum x_k^2) \beta_2^2, \\ \beta^T X^T Y &= Y^T X \beta = [\beta_1, \beta_2] \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_m \end{bmatrix} \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = m\bar{y}\beta_1 + (\sum x_k y_k) \beta_2, \\ Y^T Y &= \sum y_k^2. \end{aligned} \quad (3)$$

Równania (3) pozwalają na zapisanie funkcji $g(\beta_1, \beta_2) = \|X \cdot \beta - Y\|_2^2$ w postaci skalarnej. Obliczając pochodne cząstkowe $\frac{\partial g}{\partial \beta_1}, \frac{\partial g}{\partial \beta_2}$ i przyrównując je do zera otrzymujemy równania

$$\begin{cases} 2m\beta_1 + 2m\bar{x}\beta_2 - 2m\bar{y} = 0, \\ 2(\sum x_k^2)\beta_2 + 2m\bar{x} - 2\sum x_k y_k = 0. \end{cases}$$

Rozwiązanie powyższego układu jest identyczne z rozwiązaniem układu (2) co dowodzi następujące

Twierdzenie 1. *Współczynniki równania regresji β minimalizują wartość wyrażenia $g(\beta_1, \beta_2) = \|X \cdot \beta - Y\|_2^2 = \beta^T X^T X \beta - 2 \cdot Y^T X \beta_1 + Y^T Y$.*

Przejdźmy teraz do zadania aproksymacji średniokwadratowej. Dla danych punktów x_1, \dots, x_m określmy iloczyn skalarny funkcji $s(x), t(x)$ następująco: $\langle s, t \rangle = \sum_{k=1}^m s(x_k) t(x_k)$. Niech oprócz tego dana będzie funkcja $y(x)$, tzn. wektor $Y = [y_1, \dots, y_m]^T$. Szukamy elementu najlepszej aproksymacji dla funkcji $y(x)$ z podprzestrzeni rozpiętej przez funkcje $\mathbb{1}, \mathbb{X}$.

Wiadomo¹, że element najlepszej aproksymacji jest określony przez układ równań normalnych

$$\begin{bmatrix} \langle \mathbb{1}, \mathbb{1} \rangle & \langle \mathbb{1}, \mathbb{X} \rangle \\ \langle \mathbb{X}, \mathbb{1} \rangle & \langle \mathbb{X}, \mathbb{X} \rangle \end{bmatrix} \cdot \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} \langle \mathbb{1}, Y \rangle \\ \langle \mathbb{X}, Y \rangle \end{bmatrix}. \quad (4)$$

Liczby α_1, α_2 to współczynniki elementu optymalnego względem funkcji $\mathbb{1}, \mathbb{X}$, tzn. $w_1(x) = \alpha_1 + \alpha_2 x$. Korzystając z postaci funkcji (wektorów) $\mathbb{1}$ oraz \mathbb{X} układ równań (4) przybiera postać

$$\begin{bmatrix} m & m\bar{x} \\ m\bar{x} & \sum x_k^2 \end{bmatrix} \cdot \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} m\bar{y} \\ \sum x_k y_k \end{bmatrix}, \quad (5)$$

identyczną z układem równań określonym wzorami (2).

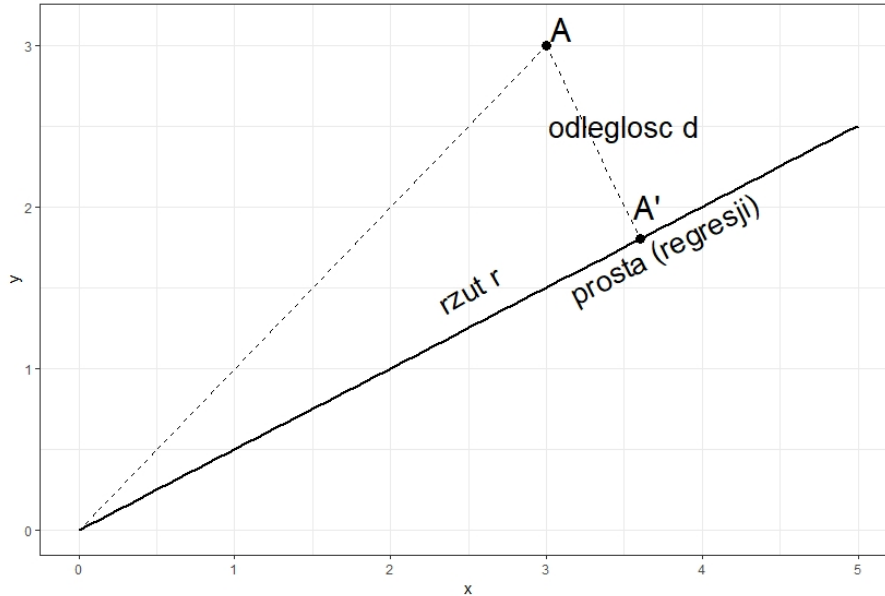
Przypomnijmy dodatkowo, że $w_n(x) \in \text{lin}\{g_1(x), \dots, g_n(x)\}$ jest elementem najlepszej aproksymacji dla funkcji $f(x)$ wtedy i tylko wtedy gdy $f - w_n \perp g_k$. Oznacza to, że:

1. prosta regresji zmiennej Y względem zmiennej X to pierwszy wielomian optymalny dla funkcji $y(x)$,
2. prosta regresji powstaje poprzez rzut prostokątny funkcji $y(x)$ na przestrzeń rozpiętą przez wektory (funkcje) $\mathbb{1}, \mathbb{X}$,
3. minimalizacja odległości pomiędzy punktami (x_i, y_i) a prostą regresji jest równoważna maksymalizacji długości rzutu punktów (x_i, y_i) na prostą (regresji).

¹Analiza Numeryczna.

Krótkie objaśnienie do ostatniego z powyższych punktów.

Rozważmy punkt A jak na rysunku poniżej. Prosta regresji zaznaczona jest linią ciągłą, natomiast linią przerywaną długość odcinka OA oraz odległość punktu A od prostej (odcinek AA'). Rzutujemy punkt w sposób prostokątny w związku z tym $OA^2 = r^2 + d^2$.




Ponieważ długość OA jest stała więc minimalizacja odległości d jest równoważna maksymalizacji długości rzutu r . Prosta oznacza w ogólności podprzestrzeń w której szukamy elementu najlepszej aproksymacji (dowolna przestrzeń zawiera wektor zerowy, stąd prosta przechodzi przez punkt 0). Punkt A (funkcję $y(x)$) rzutujemy prostokątnie na podprzestrzeń.

Przekształcenia liniowe


Przykład:

Rozpatrzmy macierz $A = \begin{pmatrix} 3 & 2 \\ 2 & 3 \end{pmatrix}$. Jej wartości własne to $\lambda_1 = 5$ oraz $\lambda_2 = 1$. Rysunek poniżej ilustruje obraz okręgu i kwadratu jednostkowego dla przekształcenia A . Obrazem okręgu jest elipsa o półosiach 5 oraz 1, obrazem kwadratu jest równoległobok o przekątnych $5\sqrt{2}, 1$. Tak elipsa jak i równoległobok są obrócone o 45° .

Jest tak dlatego, że ortonormalne wektory własne macierzy A tworzą macierz obrotu o elementach $\frac{1}{2} \begin{pmatrix} \sqrt{2} & \sqrt{2} \\ -\sqrt{2} & \sqrt{2} \end{pmatrix}$.



(a) Koło i jego obraz



(b) Kwadrat i jego obraz

Rozkład SVD – c.d.

Powracamy do rozkładu SVD.

Twierdzenie 2. Niech $A \in \mathbb{R}^{m \times n}$. Wówczas istnieją macierze $U \in \mathbb{R}^{m \times m}$, $\Sigma \in \mathbb{R}^{m \times n}$ oraz $V \in \mathbb{R}^{n \times n}$ takie, że

$$A = U \Sigma V^T,$$

gdzie macierze U, V są ortogonalne, macierz $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_p)$, $\sigma_1 \geq \dots, \sigma_p \geq 0$ oraz $p = \min\{m, n\}$.

Przypomnijmy też, że macierze U, V to ortonormalne wektory własne dla AA^T oraz $A^T A$. Liczby $\sigma_1^2 \geq \dots \geq \sigma_r^2 > 0$, gdzie $r \leq \min\{m, n\}$, to (niezerowe) wartości własne macierzy AA^T oraz $A^T A$.

Twierdzenie 3. Niech u_k, v_k będą k -tymi kolumnami macierzy U, V z twierdzenia 2. Zachodzi wówczas równość $Av_k = \sigma_k u_k$, $k = 1, \dots, p$.

Dowód. Niech v_k będzie wektorem własnym odpowiadającym wartości własnej σ_k^2 macierzy $A^T A$. Jest zatem $A^T A v_k = \sigma_k^2 v_k$. Określmy wektor u_k następująco: $u_k = Av_k / \sigma_k$.

Sprawdźmy czy u_k jest wektorem własnym macierzy AA^T :

$$AA^T u_k = \frac{1}{\sigma_k} A (A^T A v_k) = \frac{1}{\sigma_k} A \sigma_k^2 v_k = \sigma_k A v_k = \sigma_k^2 u_k.$$

□

Zadania

1. Niech $V_1 = A^T U_1 \bar{\Sigma}^{-1}$, gdzie $A \in \mathbb{R}^{m \times n}$, $U_1 \in \mathbb{R}^{m \times r}$, $\bar{\Sigma} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_r})$. Kolumny macierzy U_1 to ortonormalne wektory własne, odpowiadające niezerowym wartościom własnym macierzy AA^T . Sprawdzić, że $V_1^T V_1 = I_r$.
2. Niech $V_2 = A^T U_2 \bar{\Sigma}^{-1}$. Wykazać, że $V_2^T V_2 = I$ oraz $V_1^T V_2 = \mathbb{O}$.
3. Znaleźć macierz symetryczną 2×2 o wartościach własnych $\lambda_1 = 4$, $\lambda_2 = 0.25$. Czym jest obraz okręgu jednostkowego i kwadratu jednostkowego poprzez przekształcenie A ?
4. Rozważmy macierz $A \in \mathbb{R}^{n \times n}$. Wykazać, że wartości własne macierzy A i A^T są takie same.
5. Niech $A \in \mathbb{R}^{m \times n}$. Co można powiedzieć o wartościach własnych macierzy AA^T i macierzy $A^T A$. Załóżmy dla przykładu, że $m \geq n$.
6. **2p.** Dana jest macierz $A = \begin{pmatrix} 1 & -1 \\ 1 & 1 \\ -1 & -1 \end{pmatrix}$.
 - (a) Znaleźć wartości szczególne (σ_k) macierzy A .
 - (b) Sprawdzić, że jeżeli $V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$, to zachodzi $A^T A V = V \Sigma^T \Sigma$.
 - (c) Korzystając z tw. 3 obliczyć wektory u_1, u_2 .
 - (d) Jak wybrać wektor u_3 ?